

4. Logistic Regression

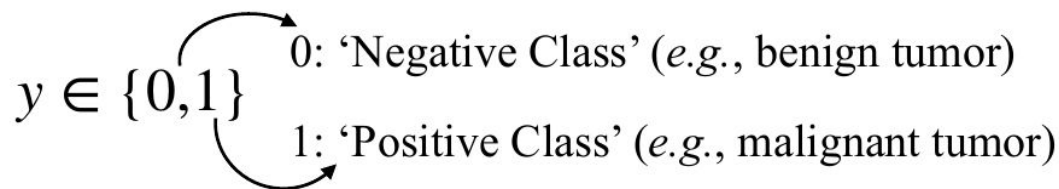
4.1 Classification

Krittameth Teachasrisaksakul

Classification (การจำแนกประเภท): ความเข้าใจพื้นฐาน

เราจะพิจารณา**ปัญหา binary classification** : ผล y เป็นไปได้ 2 ค่า คือ 0, 1 (False, True)

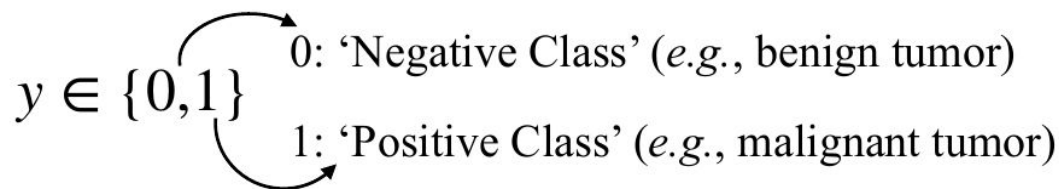
- Email: spam / ไม่ใช่ spam ?
- ธุรกรรมทางการเงินออนไลน์ (online transactions): fraudulent หลอกหลวง (ใช่ / ไม่ใช่) ?
- เนื้องอก (tumor): malignant (ร้าย) / benign (ไม่ร้าย) ?



Classification (การจำแนกประเภท): ความเข้าใจพื้นฐาน

เราจะพิจารณา **ปัญหา binary classification** : ผล y เป็นไปได้ 2 ค่า คือ 0, 1 (False, True)


- Email: spam / ไม่ใช่ spam ?
- ธุรกรรมทางการเงินออนไลน์ (online transactions): fraudulent หลอกหลวง (ใช่ / ไม่ใช่) ?
- เนื้องอก (tumor): malignant (ร้าย) / benign (ไม่ร้าย) ?




(ในบทเรียนหลังจากนี้) เราจะพิจารณากรณี multi-classes (มากกว่า 2 class) เช่น $y \in \{0, 1, 2, 3\}$

ก็คือ '**multi-classes classification problem**' (ปัญหาการจำแนกประเภทที่มีมากกว่า 2 class)

Classification : ความเข้าใจพื้นฐาน



Classification : ความเข้าใจพื้นฐาน



บางคนอาจคิดว่า model นี้ น่าจะ work แต่อาจทำงานไม่ดี


วิธีหนึ่งที่จะทำ classification :
ใช้ linear regression เพื่อใช้ x ทำนาย y
โดย map (เชื่อมโยง) $h_{\theta}(x)$ ไปหา y

- $h_{\theta}(x)$ = ค่าที่ linear regression ทำนาย
- y = ผล (class)

ค่า threshold ของ $h_{\theta}(x)$ ที่ 0.5 เพื่อบอก classifier output (ผล/คำตอบจากตัวแยกประเภท):

- ถ้า $h_{\theta}(x) \geq 0.5 \rightarrow$ ทำนาย $y = 1$
- ถ้า $h_{\theta}(x) \leq 0.5 \rightarrow$ ทำนาย $y = 0$


Classification : ความเข้าใจพื้นฐาน



ค่า threshold ของ $h_{\theta}(x)$ ที่ 0.5 เพื่อบอก classifier output (ผล/คำตอบจากตัวแยกประเภท):

- ถ้า $h_{\theta}(x) \geq 0.5 \rightarrow$ ทำนาย $y = 1$
- ถ้า $h_{\theta}(x) \leq 0.5 \rightarrow$ ทำนาย $y = 0$

Classification : ความเข้าใจพื้นฐาน



ค่า threshold ของ $h_{\theta}(x)$ ที่ 0.5 เพื่อบอก classifier output (ผล/คำตอบจากตัวแยกประเภท):

- ถ้า $h_{\theta}(x) \geq 0.5 \rightarrow$ ทำนาย $y = 1$
- ถ้า $h_{\theta}(x) \leq 0.5 \rightarrow$ ทำนาย $y = 0$

$y \in \{0, 1\}$: ผล classification (classification output)

- y เป็นไปได้ 2 ค่า คือ 0 หรือ 1 เท่านั้น

แต่ $h_{\theta}(x)$ มีค่า > 1 หรือ < 0 ก็ได้

วิธีนี้ (ใช้ linear regression ทำ classification) จึงทำงานได้แย่มาก

คำถาม


คำกล่าวข้อใดเป็นจริง ?

- (i) ถ้า linear regression ใช้ทำ classification ไม่ได้ผล (ในตัวอย่างก่อนหน้านี้) การทำ feature scaling อาจช่วยได้
- (ii) ถ้าชุดข้อมูล training set ทำให้ $0 \leq y^{(i)} \leq 1$ เป็นจริง สำหรับ training example ทุกอัน $(\mathbf{x}^{(i)}, y^{(i)})$ แล้วผลทำนายของ linear regression จะทำให้ $0 \leq h_{\theta}(\mathbf{x}) \leq 1$ เป็นจริง สำหรับทุกๆค่าของ \mathbf{x}
- (iii) ถ้ามี feature \mathbf{x} ที่ทำนาย y ได้อย่างสมบูรณ์แบบ ก็คือ ถ้า $y = 1$ เมื่อ $\mathbf{x} \geq c$ และ $y = 0$ เมื่อ $\mathbf{x} < c$ (เมื่อ c เป็นค่าคงที่) แล้ว linear regression จะมี classification error เป็น 0 (ศูนย์)
- (iv) ไม่มีคำกล่าวใดถูกต้อง

คำถาม

คำกล่าวข้อใดเป็นจริง ?

- (i) ถ้า linear regression ใช้ทำ classification ไม่ได้ผล (ในตัวอย่างก่อนหน้านี้) การทำ feature scaling อาจช่วยได้
- (ii) ถ้าชุดข้อมูล training set ทำให้ $0 \leq y^{(i)} \leq 1$ เป็นจริง สำหรับ training example ทุกอัน $(\mathbf{x}^{(i)}, y^{(i)})$ แล้วผลทำนายของ linear regression จะทำให้ $0 \leq h_{\theta}(\mathbf{x}) \leq 1$ เป็นจริง สำหรับทุกๆค่าของ \mathbf{x}
- (iii) ถ้ามี feature \mathbf{x} ที่ทำนาย y ได้อย่างสมบูรณ์แบบ ก็คือ ถ้า $y = 1$ เมื่อ $\mathbf{x} \geq c$ และ $y = 0$ เมื่อ $\mathbf{x} < c$ (เมื่อ c เป็นค่าคงที่) แล้ว linear regression จะมี classification error เป็น 0 (ศูนย์)
- (iv) ไม่มีคำกล่าวใดถูกต้อง



4. Logistic Regression

4.2 Hypothesis Representation

(การเขียนอธิบาย Hypothesis
ด้วยสัญลักษณ์คณิตศาสตร์)

Krittameth Teachasrisaksakul

Logistic Regression Model

$$0 \leq h_{\theta}(x) \leq 1$$

การปรับปรุง: เปลี่ยนรูปแบบของ hypothesis function $h_{\theta}(x)$ เพื่อจำกัดค่าของมันอยู่ในช่วง $[0, 1]$

โดยแทนค่า $\theta^T x$ ใน logistic function

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

นิยามของ function g :

$$g(z) = \frac{1}{1 + e^{-z}}$$

Function นี้ เรียกว่า **logistic sigmoid function** หรือ **sigmoid function**

Logistic Regression Model

อยากให้ $0 \leq h_{\theta}(x) \leq 1$

เพราะอยากทำ binary classification ที่ผลเป็นไปได้ 2 ค่า คือ 0, 1 (true, false)

การปรับปรุง: เปลี่ยนรูปแบบของ hypothesis function h เพื่อจำกัดค่าของมันอยู่ในช่วง $[0, 1]$:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

นิยามของ function g :

$$g(z) = \frac{1}{1 + e^{-z}}$$

เป้าหมาย: หาค่า parameter θ ที่เหมาะกับข้อมูล
(fit parameter θ to the data)


Function นี้ เรียกว่า **logistic sigmoid function** หรือ **sigmoid function**

Logistic Sigmoid Function

```
import numpy
import matplotlib.pyplot as plt

def f(z):
    return 1/(1 + numpy.exp(-z))

z = numpy.arange(-5, 5, 0.1)
plt.plot(z, f(z), 'b')
plt.xlabel('z')
plt.ylabel('g(z)')
plt.title('Logistic sigmoid function')
```



การอ่านผล / output ของ Hypothesis

$$h_{\theta}(\mathbf{x}) = g(\boldsymbol{\theta}^T \mathbf{x}) = \frac{1}{1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}}$$

การประมาณค่า ความน่าจะเป็น (probability) ที่ $y = 1$ เมื่อมี input \mathbf{x}

การอ่านผล / output ของ Hypothesis

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

การประมาณค่า ความน่าจะเป็น (probability) ที่ $y = 1$ เมื่อมี input x

ตัวอย่าง: สมมติ

$$x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tumorSize} \end{bmatrix} \text{ and } h_{\theta}(x) = 0.7$$

นี่หมายความว่า มีโอกาส 70% ที่เนื้องอกจะเป็นเนื้อร้าย (malignant)

การอ่านผล / output ของ Hypothesis

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

การประมาณค่า ความน่าจะเป็น (probability) ที่ $y = 1$ เมื่อมี input x

ตัวอย่าง: สมมติ

$$x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tumorSize} \end{bmatrix} \text{ and } h_{\theta}(x) = 0.7$$

นี้หมายความว่า มีโอกาส 70% ที่เนื้องอกจะเป็นเนื้อร้าย (malignant)

เขียนในทางคณิตศาสตร์ว่า

$$h_{\theta}(x) = P(y = 1 \mid x; \theta)$$

‘ความน่าจะเป็นที่ $y = 1$ เมื่อรู้ค่า x และมี parameter เป็น θ ’

คำถาม

สมมติ เราอยากทำนายจากข้อมูล \mathbf{x} เกี่ยวกับเนื้ออกว่ามันเป็นเนื้อร้าย ($y = 1$) หรือไม่ร้าย ($y = 0$) ตัวแบ่งประเภท (classifier) แบบ logistic regression บอกผลของเนื้ออกแต่ละอัน $h_\theta(\mathbf{x}) = P(y = 1 | \mathbf{x}; \theta) = 0.7$ ดังนั้น เราประมาณค่าว่ามีโอกาส 70% ว่าเนื้ออกจะเป็นเนื้อร้าย ค่าประมาณของ $P(y = 0 | \mathbf{x}; \theta)$ ความน่าจะเป็นที่เนื้ออกไม่ร้าย

(i) $P(y = 0 | \mathbf{x}; \theta) = 0.3$

(ii) $P(y = 0 | \mathbf{x}; \theta) = 0.7$

(iii) $P(y = 0 | \mathbf{x}; \theta) = 0.7^2$

(iv) $P(y = 0 | \mathbf{x}; \theta) = 0.3 \times 0.7$

คำใบ้:

$$P(y = 0 | \mathbf{x}; \theta) + P(y = 1 | \mathbf{x}; \theta) = 1$$

คำถาม

สมมติ เราอยากทำนายจากข้อมูล x เกี่ยวกับเนื้ออกว่ามันเป็นเนื้อร้าย ($y = 1$) หรือไม่ร้าย ($y = 0$) ตัวแบ่งประเภท (classifier) แบบ logistic regression บอกผลของเนื้ออกแต่ละอัน $h_\theta(x) = P(y = 1 | x; \theta) = 0.7$ ดังนั้น เราประมาณค่าว่ามีโอกาส 70% ว่าเนื้ออกจะเป็นเนื้อร้าย ค่าประมาณของ $P(y = 0 | x; \theta)$ ความน่าจะเป็นที่เนื้ออกไม่ร้าย

(i) $P(y = 0 | x; \theta) = 0.3$

(ii) $P(y = 0 | x; \theta) = 0.7$

(iii) $P(y = 0 | x; \theta) = 0.7^2$

(iv) $P(y = 0 | x; \theta) = 0.3 \times 0.7$

คำใบ้:

$$P(y = 0 | x; \theta) + P(y = 1 | x; \theta) = 1$$

4. Logistic Regression

4.3 Decision Boundary (เส้นขอบเขตตัดสินใจ)

Krittameth Teachasrisaksakul

Decision boundary : ความเข้าใจพื้นฐาน

พฤติกรรมของฟังก์ชัน logistic regression หรือ g คือ
เมื่อ **$input \geq 0$** จะได้ **$output \geq 0.5$**


$$\therefore \text{เมื่อ } z \geq 0 \rightarrow g(z) \geq 0.5$$

$$\therefore \text{เมื่อ } \theta^T x \geq 0 \rightarrow h_{\theta}(x) = g(\theta^T x) \geq 0.5$$

Hypothesis:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

$P(y = 1 | x; \theta)$



เพื่อทำ classification ให้ได้ค่า 0 หรือ 1 เราจะแปลง output ของ hypothesis function

Decision boundary

Hypothesis:


$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

$P(y = 1 | x; \theta)$


∴ เมื่อ $z \geq 0 \rightarrow g(z) \geq 0.5$

∴ เมื่อ $\theta^T x \geq 0 \rightarrow h_{\theta}(x) = g(\theta^T x) \geq 0.5$

- ถ้า $h_{\theta}(x) \geq 0.5 \rightarrow$ ทำนาย ' $y = 1$ '
 - $\theta^T x \geq 0$
- ถ้า $h_{\theta}(x) < 0.5 \rightarrow$ ทำนาย ' $y = 0$ '
 - $\theta^T x < 0$



Decision boundary : ความเข้าใจพื้นฐาน




$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

-3 ← 1 ← 1 ←

$$i.e. \theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

Decision boundary : ความเข้าใจพื้นฐาน



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$


-3 ← 1 ← 1 ←

$$i.e. \theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

$$\therefore \theta^T x = [-3 \quad 1 \quad 1] \times \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = -3 + x_1 + x_2$$

$$\therefore \text{Predict 'y = 1' if } -3 + x_1 + x_2 \geq 0$$

Decision boundary : ความเข้าใจพื้นฐาน



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$


-3 ← 1 ← 1 ←

$$i.e. \theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

$$\therefore \theta^T x = [-3 \quad 1 \quad 1] \times \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = -3 + x_1 + x_2$$

\therefore Predict 'y = 1' if $-3 + x_1 + x_2 \geq 0 \iff x_1 + x_2 \geq 3$

Decision boundary : ความเข้าใจพื้นฐาน



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

-3 ← 1 ← 1 ←


$$\text{i.e. } \theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

$$\therefore \theta^T x = [-3 \quad 1 \quad 1] \times \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = -3 + x_1 + x_2$$

$$\therefore \text{Predict 'y = 1' if } -3 + x_1 + x_2 \geq 0 \iff x_1 + x_2 \geq 3$$

Decision boundary

Decision Boundary : เส้นที่แบ่งพื้นที่ที่ $y = 0$ และพื้นที่ที่ $y = 1$ เส้นนี้ถูกสร้างด้วย hypothesis function



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

-3 ← 1 ← 1 ←

$$\text{i.e. } \theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

$$\therefore \theta^T x = [-3 \quad 1 \quad 1] \times \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = -3 + x_1 + x_2$$

$$\therefore \text{Predict 'y = 1' if } -3 + x_1 + x_2 \geq 0 \iff x_1 + x_2 \geq 3$$


คำถาม

พิจารณา logistic regression ที่มี feature 2 ตัว: X_1 และ X_2

สมมติ $\theta_0 = 5$, $\theta_1 = -1$, $\theta_2 = 0$ ถ้าเราต้องการสร้างโมเดล

ที่มี hypothesis function: $h_\theta(x) = g(5 - x_1)$

ภาพไหนแสดง decision boundary ของ $h_\theta(x)$



คำถาม

พิจารณา logistic regression ที่มี feature 2 ตัว: X_1 และ X_2
สมมติ $\theta_0 = 5$, $\theta_1 = -1$, $\theta_2 = 0$ ถ้าเราต้องการสร้างโมเดล
ที่มี hypothesis function: $h_\theta(x) = g(5 - x_1)$
ภาพไหนแสดง decision boundary ของ $h_\theta(x)$

วิธีทำ

$$\theta = \begin{bmatrix} 5 \\ -1 \\ 0 \end{bmatrix}$$





$$\theta^T x \geq 0$$

$$y = 1 \text{ if } 5 + (-1)x_1 + 0x_2 \geq 0$$


$$5 - x_1 \geq 0$$

$$-x_1 \geq -5$$

$$x_1 \leq 5$$



Decision boundary ที่ไม่ใช่เส้นตรง (Non-linear)



✕ : positive example

○ : negative example

$$h_{\theta}(x) = g(\underbrace{\theta_0}_{-1} + \underbrace{\theta_1}_{0}x_1 + \underbrace{\theta_2}_{0}x_2 + \underbrace{\theta_3}_{1}x_1^2 + \underbrace{\theta_4}_{1}x_2^2)$$

$$i.e. \theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$$

\therefore Predict 'y = 1' if $-1 + x_1^2 + x_2^2 \geq 0$


$$\iff x_1^2 + x_2^2 \geq 1$$

Decision boundary ที่ไม่ใช่เส้นตรง (Non-linear)

Decision boundary ไม่จำเป็นต้องเป็นฟังก์ชันเส้นตรง (linear function)

Decision boundary สามารถเป็น function ที่แทนวงกลม หรือ รูปร่างอื่นๆ ที่เหมาะกับข้อมูลของเรา

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_1^2 x_2 + \theta_5 x_1^2 x_2^2 + \theta_6 x_1^3 x_2 + \dots)$$



4. Logistic Regression

4.4 Cost Function

Krittameth Teachasrisaksakul

เรามี

ชุดข้อมูล Training set:

$$\{(\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$$

เมื่อ $\mathbf{x}^{(i)} \in \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}_{\mathbb{R}^{n+1}}, x_0 = 1, y^{(i)} \in \{0,1\}$

Hypothesis:

$$h_{\theta}(\mathbf{x}) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$


เป้าหมาย: เลือก parameter ยังไง ให้ minimize cost error (ทำ cost error ให้น้อยที่สุด)

Cost error function หน้าตาเป็นยังไง ? (เป็น $\text{cost}(h_{\theta}(\mathbf{x}^{(i)}), y^{(i)})$ หรือเปล่า ?)

Cost Function ของ Logistic Regression

สิ่งที่ต้องการ:


- ถ้า $y = 1$ และ $h_{\theta}(x) = 1 \rightarrow$ แล้ว cost ต้องเป็น 0
- ถ้า $y = 1$ และ $h_{\theta}(x) = 0 \rightarrow$ แล้ว cost ควรจะมีค่า ใหญ่มาก
- ถ้า $y = 0$ และ $h_{\theta}(x) = 1 \rightarrow$ แล้ว cost ควรจะมีค่า ใหญ่มาก
- ถ้า $y = 0$ และ $h_{\theta}(x) = 0 \rightarrow$ แล้ว cost ต้องเป็น 0
- เมื่อ y เป็น output จริง และ $h_{\theta}(x)$ เป็น output ที่ประมาณค่า (ได้จาก classifier)



Cost Function ของ Logistic Regression

สิ่งที่ต้องการ: (2 กรณีแรก)


- ถ้า $y = 1$ และ $h_{\theta}(x) = 1 \rightarrow$ แล้ว cost ต้องเป็น 0
- ถ้า $y = 1$ และ $h_{\theta}(x) = 0 \rightarrow$ แล้ว cost ควรจะมีค่า ใหญ่มาก



Cost Function ของ Logistic Regression

สิ่งที่ต้องการ: (2 กรณีหลัง)

- ถ้า $y = 0$ และ $h_{\theta}(x) = 1 \rightarrow$ แล้ว cost ควรจะมีค่าใหญ่มาก
- ถ้า $y = 0$ และ $h_{\theta}(x) = 0 \rightarrow$ แล้ว cost ต้องเป็น 0



Cost Function ของ Logistic Regression

$$\text{cost}(h_{\theta}(\mathbf{x}^{(i)}), y^{(i)}) = \begin{cases} -\log(h_{\theta}(\mathbf{x}^{(i)})) & \text{if } y^{(i)} = 1 \\ -\log(1 - h_{\theta}(\mathbf{x}^{(i)})) & \text{if } y^{(i)} = 0 \end{cases}$$

ยุบรวม cost function ที่มี 2 กรณี ให้เหลือสมการเดียว

เขียนใหม่ ในรูปแบบที่กระชับ: cost function ของ 1 training example

$$\text{cost}(h_{\theta}(\mathbf{x}^{(i)}), y^{(i)}) = -y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)}))$$

ถ้า $y = 0 \rightarrow$
พจน์ที่ 1 จะเป็น 0 และ ไม่มีผลกับ
ผลลัพธ์

ถ้า $y = 1 \rightarrow$
พจน์ที่ 2 จะเป็น 0 และ
ไม่มีผลกับผลลัพธ์

Cost Function ของ Logistic Regression

เพราะ

$$\mathbf{cost}(h_{\theta}(\mathbf{x}^{(i)}), y^{(i)}) = -y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)}))$$

ดังนั้น เขียน cost function แบบเต็มๆ ได้เป็น

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \mathbf{cost}(h_{\theta}(\mathbf{x}^{(i)}), y^{(i)})$$

cost function ของ training example ทั้งหมด : training example
ที่ $i=1$ ถึง $i=m$

$$= -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)})) \right]$$

เรามี

Cost function:

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)})) \right]$$

เป้าหมาย:

$$\min_{\theta} J(\theta)$$

เพื่อทำนายผล โดยใช้ค่า \mathbf{x} ใหม่:

$$h_{\theta}(\mathbf{x}) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

ก็คือ ความน่าจะเป็นที่ $y = 1$ เมื่อรู้ค่า \mathbf{x} และมี parameter เป็น θ

เรามี

เป้าหมาย: $\min_{\theta} J(\theta)$

Minimize cost function ด้วยวิธี gradient descent อย่างไร ?

ทำซ้ำ จน converge

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)}) \mathbf{x}_j^{(i)} \right]$$

$\nabla_J(\theta)$

ใช้ algorithm เดียวกับที่ใช้ใน linear regression

(ปรับค่า θ_j ทุกตัวพร้อมกัน)

คำถาม

สมมติเรา run gradient descent เพื่อหา parameter $\theta \in \mathbb{R}^{n+1}$ ของโมเดล logistic regression ข้อใดที่เป็นวิธีที่เหมาะสมที่ทำให้แน่ใจว่าค่า learning rate α เป็นค่าที่เหมาะสม และ gradient descent ทำงานอย่างถูกต้อง

- (i) Plot $J(\theta) = (1/m) \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$ เป็นฟังก์ชันของจำนวน iterations (การวนซ้ำ)
(ก็คือ แกะ) หลังทุก iteration
- (ii) Plot $J(\theta) = (-1/m) \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$
เป็นฟังก์ชัน
- (iii) Plot $J(\theta)$ เป็นฟังก์ชันของ θ และทำให้แน่ใจว่า $J(\theta)$ ลดลง หลังทุก iteration
- (iv) Plot $J(\theta)$ เป็นฟังก์ชันของ θ และทำให้แน่ใจว่า $J(\theta)$ เป็นกราฟ convex

คำถาม

สมมติเรา run gradient descent เพื่อหา parameter $\theta \in \mathbb{R}^{n+1}$ ของโมเดล logistic regression ข้อใดที่เป็นวิธีที่เหมาะสมที่ทำให้แน่ใจว่าค่า learning rate α เป็นค่าที่เหมาะสม และ gradient descent ทำงานอย่างถูกต้อง

(i) Plot $J(\theta) = (1/m) \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$ เป็นฟังก์ชันของจำนวน iterations (การวนซ้ำ)
(ก็คือ แกะ) หลังทุก iteration

(ii) Plot $J(\theta) = (-1/m) \sum_{i=1}^m [y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$ เป็นฟังก์ชัน

(iii) Plot $J(\theta)$ เป็นฟังก์ชันของ θ และทำให้แน่ใจว่า $J(\theta)$ ลดลง หลังทุก iteration

(iv) Plot $J(\theta)$ เป็นฟังก์ชันของ θ และทำให้แน่ใจว่า $J(\theta)$ เป็นกราฟ convex

4. Logistic Regression

4.5 Multi-class Classification

(การจำแนกประเภทที่มีมากกว่า 2 class)

Krittameth Teachasrisaksakul

Multi-class classification : ความเข้าใจพื้นฐาน

- การจัดกลุ่ม email ใส่ folder: งาน, เพื่อน, ครอบครัว, งานอดิเรก

$$y = 1 \quad y = 2 \quad y = 3 \quad y = 4$$

- การวินิจฉัยโรค: ไม่ป่วย, เป็นหวัด, เป็นไข้


$$y = 1 \quad y = 2 \quad y = 3$$

- สภาพอากาศ: มีแดดมาก, มีเมฆมาก, ฝนตก


$$y = 1 \quad y = 2 \quad y = 3$$

Binary vs. Multi-class

Binary classification




Multi-class classification




Binary vs. Multi-class

Binary classification




Regression algorithm

Multi-class classification



One-vs-all algorithm

One-vs-all (One-vs-rest)




Class 1: \triangle ($y = 1$)

Class 2: \square ($y = 2$)

Class 3: \times ($y = 3$)

One-vs-all หรือ One-vs-rest คือ การแยกประเภท class 1 class ออกจาก class ที่เหลือทั้งหมด


One-vs-all (One-vs-rest)



Class 1: \triangle ($y = 1$)


Class 2: \square ($y = 2$)

Class 3: \times ($y = 3$)



แยก class 1 จาก class อื่นๆ ทั้งหมด (class 2, 3)



One-vs-all (One-vs-rest)




Class 1: \triangle ($y = 1$)

Class 2: \square ($y = 2$)

Class 3: \times ($y = 3$)




$h_{\theta}^{(1)}(\mathbf{x})$



$h_{\theta}^{(2)}(\mathbf{x})$

แยก class 2 จาก class อื่นๆ ทั้งหมด (class 1, 3)


One-vs-all (One-vs-rest)




Class 1: \triangle ($y = 1$)

Class 2: \square ($y = 2$)


Class 3: \times ($y = 3$)



$h_{\theta}^{(1)}(\mathbf{x})$




$h_{\theta}^{(2)}(\mathbf{x})$



$h_{\theta}^{(3)}(\mathbf{x})$

แยก class 3 จาก class อื่นๆ ทั้งหมด (class 1, 2)

One-vs-all (One-vs-rest)




Class 1: \triangle ($y = 1$)


Class 2: \square ($y = 2$)

Class 3: \times ($y = 3$)


$$h_{\theta}^{(i)}(x) = P(y = i | x; \theta) \quad (i = 1, 2, 3)$$



$$h_{\theta}^{(1)}(x) \quad 0.7$$



$$h_{\theta}^{(2)}(x) \quad 0.2$$



$$h_{\theta}^{(3)}(x) \quad 0.1$$

One-vs-all : ขั้นตอน multiclass classification โดยใช้ binary logistic regression

- ฝึก (Train) / สร้าง logistic regression classifier (ตัวจำแนก) $h_{\theta}^{(i)}(x)$ ของแต่ละ class (ประเภท) i เพื่อทำนายความน่าจะเป็นที่ $y = i$ (หมายความว่า ตัวอย่างข้อมูลนี้ จัดเป็นประเภท i)
- เพื่อทำนาย class ของ input ใหม่ $x \rightarrow$ เลือก class i ที่ทำให้ $h_{\theta}^{(i)}(x)$ มีค่าสูงสุด ก็คือ

$$y = \arg \max_i h_{\theta}^{(i)}(x)$$

$y = 1$

คำถาม

สมมติ เรามีปัญหา multi-class classification (การแบ่งประเภทมากกว่า 2 ประเภท) ที่มี k classes (ประเภท) (ดังนั้น $y \in \{1, 2, \dots, k\}$) ถ้าใช้วิธี one-vs-all จะต้อง train logistic regression classifier ทั้งหมดกี่ตัว

(i) $k - 1$

(ii) k

(iii) $k + 1$

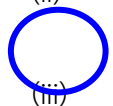
(iv) ประมาณ $\log_2(k)$

คำถาม

สมมติ เรามีปัญหา multi-class classification (การแบ่งประเภทมากกว่า 2 ประเภท) ที่มี k classes (ประเภท) (ดังนั้น $y \in \{1, 2, \dots, k\}$) ถ้าใช้วิธี one-vs-all จะต้อง train logistic regression classifier ทั้งหมดกี่ตัว

(i) $k - 1$

(ii) k

 (iii) $k + 1$

(iv) ประมาณ $\log_2(k)$

สรุป

1. ถ้ามี \mathcal{X} ที่มีค่าต่อเนื่อง (continuous) และอยากทำนาย \mathcal{Y} ที่มีค่าต่อเนื่อง
ให้ลองใช้ **linear regression** model เป็นอันแรก
2. ถ้ามี \mathcal{X} ที่มีค่าต่อเนื่อง (continuous) และอยากทำนาย \mathcal{Y} ที่มีค่าไม่ต่อเนื่อง (discrete)
ให้ลองใช้ **logistic regression** model เป็นอันแรก

วิธีที่เราเรียน คือ การเรียนรู้ $p(y | x)$ โดยตรง ก็คือ เมื่อให้ input \mathbf{x} เราจะแปลง (map) ไปเป็น target (เป้าหมาย / ผล) y โดยตรง

วิธีพวกนี้ เรียกว่า **discriminative** learning algorithms

References

1. Andrew Ng, Machine Learning, Coursera.
2. Teeradaj Racharak, AI Practical Development Bootcamp.
3. What is Machine Learning?, <https://www.digitalskill.org/contents/5>